



Proyecto Final Data Science

“Análisis territorial y modelo de clasificación para la mortalidad infantil por malformaciones congénitas”

Entrega final

- **Integrante:** Nicolás Martín
- **Comisión:** 95310
- **Docente:** Jorge Ruiz

2026

Índice

1. Resumen Ejecutivo	3
2. Introducción	3
2.1 Contexto comercial / institucional	3
2.2 Objetivos	4
2.3 Hipótesis	4
2.4 Variables del estudio	4
3. Fuentes de Datos y Metodología	4
3.1 Pipeline de limpieza y filtrado (procesar_csv)	5
4. Análisis Exploratorio de Datos (EDA)	5
4.1 Análisis de valores faltantes	5
4.2 Distribución nacional de casos	7
4.3 Análisis territorial: defunciones y tasa de mortalidad	8
4.3.1 Tasa de mortalidad por región	9
4.3.2 Números absolutos por provincia, región y tipo de malformación	9
4.3.3 Tasa por tipo de malformación y provincia (comparación normalizada)	10
4.3.4 Distribución por región y tipo de malformación	12
4.4 Estadísticas descriptivas de la tasa de mortalidad	13
4.5 Análisis etario	14
5. Preprocesamiento y Reducción de Dimensionalidad	15
6. Modelado Predictivo	16
6.1 Regresión Logística	16
6.2 Optimización de hiperparámetros (GridSearchCV)	16
6.3 Random Forest	17
7. Evaluación y Comparación de Modelos	18
8. Conclusiones	19

1. Resumen Ejecutivo

Este informe analiza la mortalidad infantil por malformaciones congénitas en Argentina durante el año 2024, a partir de microdatos publicados por la Dirección de Estadísticas e Información de Salud (DEIS). Tras un proceso de limpieza y transformación, el dataset de trabajo quedó conformado por 611 registros correspondientes a defunciones de menores de un año cuya causa básica corresponde a códigos CIE-10 del capítulo Q (malformaciones congénitas), que representan un total de 1.013 casos agregados.

El trabajo persigue dos objetivos complementarios: por un lado, cuantificar y comparar la tasa de mortalidad infantil por provincia y región geográfica para identificar desigualdades territoriales; por otro, construir un modelo de clasificación que permita predecir si una defunción corresponde a una cardiopatía congénita (Q20-Q28) o a otro tipo de malformación, a partir de variables geográficas y etarias.

Los principales hallazgos muestran una brecha territorial marcada — las regiones NEA y Cuyo presentan las tasas de mortalidad más altas (3,46 y 2,85 por mil nacidos vivos, respectivamente), frente a Patagonia y la región Pampeana, con tasas más bajas — y una concentración de los casos en el período neonatal precoz. Los modelos de clasificación evaluados (Regresión Logística y Random Forest) alcanzaron un desempeño perfecto ($F1 = 1,00$, $AUC-ROC = 1,00$), resultado que se explica por la relación determinista entre la variable CAUSA y la variable objetivo, y que se discute en detalle en las conclusiones.

2. Introducción

En este trabajo se analizan datos extraídos del sitio web de la Dirección de Estadísticas e Información de Salud (DEIS) del Estado argentino. El objetivo es analizar la mortalidad infantil por malformaciones congénitas en Argentina durante el año 2024, con foco en la distribución territorial y etaria de los casos.

2.1 Contexto comercial / institucional

El Ministerio de Salud de la Nación identificó un aumento en la tasa de mortalidad infantil en el último relevamiento demográfico correspondiente al año 2024, de 0,5 puntos por encima de 2023. Ante este escenario, surge la necesidad de analizar en profundidad las causas de muerte en menores de un año, con foco en las malformaciones congénitas, que representan la segunda causa de mortalidad infantil en Argentina. El análisis busca brindar información que oriente la toma de decisiones en políticas públicas de salud, priorizando la detección prenatal de cardiopatías congénitas y la reducción de las brechas regionales existentes.

2.2 Objetivos

El presente trabajo tiene dos objetivos complementarios:

- Desarrollar un modelo de clasificación que permita predecir si una defunción infantil por malformación congénita corresponde a una cardiopatía congénita (Q20-Q28) o a otra malformación congénita, en función del subgrupo etario y la provincia de residencia.
- Analizar la tasa de mortalidad infantil por provincia y región geográfica, con el fin de identificar desigualdades territoriales en el acceso a la salud materno-infantil en Argentina durante 2024.

2.3 Hipótesis

Un modelo de aprendizaje automático podrá clasificar con precisión las defunciones infantiles por malformación congénita en cardiopatías congénitas o en otras malformaciones, a partir del subgrupo etario y la provincia de residencia, esperando alcanzar un F1-score superior a 0,70. Asimismo, se espera evidenciar patrones de desigualdad territorial, con tasas de mortalidad infantil por malformaciones congénitas significativamente más elevadas en las regiones NOA y NEA respecto de las regiones Pampeana y Patagónica.

2.4 Variables del estudio

Tipo	Variable	Descripción
VD (objetivo)	ENFERMEDAD	Tipo de malformación congénita: cardiopatías congénitas (Q20-Q28) vs. otras malformaciones
VI	PROVINCIA	Provincia de residencia del fallecido
VI	REGION	Región geográfica (NOA, NEA, Cuyo, Pampeana, Patagónica)
VI	PER_DEF / EDAD_DEF	Subgrupo etario de la defunción (neonatal precoz, neonatal tardío, postneonatal)
Auxiliar	CANTIDAD / CAUSA	Cantidad de casos agregados y código CIE-10 de la causa de defunción

3. Fuentes de Datos y Metodología

Se utilizaron dos fuentes de la DEIS: (1) un archivo de defunciones por causa, provincia, sexo y grupo etario, y (2) un archivo de nacidos vivos por provincia, necesario para calcular tasas de mortalidad normalizadas. El dataset original de defunciones contiene 54.251 filas y 6 columnas, correspondientes a todas las causas de muerte registradas en el país durante 2024 (no solo mortalidad infantil por malformaciones).

La tasa de mortalidad infantil por malformaciones congénitas se calculó normalizando las defunciones por los nacidos vivos de cada provincia, según la fórmula estándar utilizada en demografía sanitaria:

$$\text{Tasa} = (\text{defunciones} / \text{nacidos vivos}) \times 1000$$

3.1 Pipeline de limpieza y filtrado (procesar_csv)

Sobre el dataset original se aplicó una secuencia de transformaciones para obtener el dataset de trabajo:

- Detección automática del separador y la codificación del archivo (latin1 / UTF-8).
- Eliminación de la columna MAT (99,6% de valores nulos, ver sección 4.1).
- Filtrado de registros correspondientes a mortalidad infantil (menores de 1 año) según GRUPEDAD.
- Filtrado de causas de defunción correspondientes al capítulo Q (malformaciones congénitas, CIE-10).
- Filtrado de valores válidos de SEXO y de provincia de residencia (PROVRES).
- Mapeo de código de provincia a nombre y asignación de región geográfica (NOA, NEA, Cuyo, Pampeana, Patagónica).
- Construcción del subgrupo etario (PER_DEF): neonatal precoz, neonatal tardío y post-neonatal.
- Construcción de la variable objetivo binaria ENFERMEDAD: cardiopatías (Q20-Q28) vs. otras malformaciones.

Como resultado de este pipeline, el dataset de trabajo quedó conformado por 611 registros y 7 columnas, representando 1.013 casos agregados (218 registros de cardiopatías y 393 de otras malformaciones, ponderados por la variable CANTIDAD).

4. Análisis Exploratorio de Datos (EDA)

4.1 Análisis de valores faltantes

El análisis de missingness sobre el dataset original revela un patrón claro y concentrado en una única variable:

Variable	Nulos	% Nulos
PROVRES	0	0,0%
SEXO	0	0,0%

Variable	Nulos	% Nulos
CAUSA	0	0,0%
MAT	54056	99,6%
GRUPEDAD	0	0,0%
CUENTA	0	0,0%

La variable MAT (muerte materna) presenta 99,6% de valores nulos. Este comportamiento no es aleatorio sino estructural: la variable registra si una defunción corresponde a una muerte materna, pero al filtrar mortalidad infantil por malformaciones congénitas, ningún caso puede clasificarse como muerte materna. El resto de las variables (PROVRES, SEXO, CAUSA, GRUPEDAD y CUENTA) presentan completitud del 100%. En consecuencia, se decidió descartar la columna MAT del análisis; el resto de las variables se incorporó al pipeline sin necesidad de imputación sobre datos reales.




Figura 1. Patrón de valores faltantes por fila — matriz de missingness sobre el dataset original.




Figura 2. Complejidad por columna del dataset original.

4.2 Distribución nacional de casos

A nivel nacional, del total de 1.013 defunciones infantiles por malformaciones congénitas registradas en 2024, el 53% (534 casos) corresponde a otras malformaciones y el 47% (479 casos) a cardiopatías congénitas.




Figura 3. Distribución nacional de casos por tipo de malformación congénita.

4.3 Análisis territorial: defunciones y tasa de mortalidad

La siguiente tabla presenta las defunciones absolutas, los nacidos vivos y la tasa de mortalidad infantil por malformaciones congénitas (por 1.000 nacidos vivos) para cada provincia, ordenadas de mayor a menor tasa:

Provincia	Defunciones	Nacidos vivos	Tasa (x1000)	Región
Chaco	56	14.350	3.90	NEA
La Rioja	13	3.503	3.71	Cuyo
Corrientes	45	12.538	3.59	NEA
Misiones	54	16.469	3.28	NEA
San Juan	28	8.701	3.22	Cuyo
Catamarca	12	3.866	3.10	NOA
Neuquén	19	6.790	2.80	Patagónica
San Luis	12	4.410	2.72	Cuyo
Formosa	18	6.711	2.68	NEA
Mendoza	47	18.505	2.54	Cuyo
Tucumán	41	16.661	2.46	NOA
Bs. As.	358	147.081	2.43	Pampeana
Salta	33	14.410	2.29	NOA
Santiago del Estero	26	11.401	2.28	NOA
Córdoba	77	33.873	2.27	Pampeana
Jujuy	14	6.352	2.20	NOA
Santa Fe	72	33.713	2.14	Pampeana
Río Negro	13	6.721	1.93	Patagónica
Entre Ríos	24	12.548	1.91	Pampeana
Santa Cruz	5	2.696	1.85	Patagónica
Tierra del Fuego	2	1.259	1.59	Patagónica

Provincia	Defunciones	Nacidos vivos	Tasa (x1000)	Región
CABA	34	21.454	1.58	Pampeana
Chubut	8	5.054	1.58	Patagónica
La Pampa	2	3.039	0.66	Pampeana

4.3.1 Tasa de mortalidad por región

Región	Defunciones	Nacidos vivos	Tasa (x1000)
NEA	173	50.068	3.46
Cuyo	100	35.119	2.85
NOA	126	52.690	2.39
Pampeana	567	251.708	2.25
Patagónica	47	22.520	2.09

Las regiones NEA (3,46) y Cuyo (2,85) presentan las tasas de mortalidad infantil por malformaciones congénitas más elevadas del país, seguidas por NOA (2,39). En el otro extremo, Patagonia (2,09) y la región Pampeana (2,25) muestran las tasas más bajas. A nivel provincial, Chaco (3,90), La Rioja (3,71) y Corrientes (3,59) encabezan el ranking, mientras que La Pampa (0,66), Chubut (1,58) y CABA (1,58) presentan las tasas más bajas.




Figura 4. Comparación entre números absolutos de defunciones y tasas de mortalidad normalizadas por región.

4.3.2 Números absolutos por provincia, región y tipo de malformación

Es importante notar que el ranking de provincias cambia según se observen números absolutos o tasas normalizadas: Buenos Aires concentra el mayor número absoluto de casos (358) por su volumen poblacional, pero al normalizar por nacidos vivos su tasa (2,43) se ubica en un nivel intermedio. Por esta razón, los números absolutos que siguen se presentan solo a modo de referencia de volumen; la comparación entre provincias debe hacerse siempre en base a tasas (sección 4.3.3), ya que las jurisdicciones tienen poblaciones y cantidades de nacimientos muy distintas entre sí.

Provincia	Cardiopatías	Otras malf.	Total
Bs. As.	193	165	358
Córdoba	38	39	77
Santa Fe	32	40	72
Chaco	25	31	56
Misiones	32	22	54
Mendoza	14	33	47
Corrientes	19	26	45
Tucumán	14	27	41
CABA	13	21	34
Salta	21	12	33
San Juan	15	13	28
Santiago del Estero	12	14	26
Entre Ríos	8	16	24
Neuquén	8	11	19
Formosa	6	12	18
Jujuy	6	8	14
La Rioja	3	10	13
Río Negro	5	8	13
San Luis	3	9	12

Provincia	Cardiopatías	Otras malf.	Total
Catamarca	5	7	12
Chubut	3	5	8
Santa Cruz	1	4	5
La Pampa	1	1	2
Tierra del Fuego	2	0	2

4.3.3 Tasa por tipo de malformación y provincia (comparación normalizada)

A diferencia de la tabla anterior, aquí se normaliza cada tipo de malformación por los nacidos vivos de cada provincia (x1.000), lo que permite comparar correctamente la magnitud del problema entre jurisdicciones de distinto tamaño poblacional:

Provincia	Tasa cardiopatías	Tasa otras malf.	Tasa total
Chaco	1.74	2.16	3.90
La Rioja	0.86	2.85	3.71
Corrientes	1.52	2.07	3.59
Misiones	1.94	1.34	3.28
San Juan	1.72	1.49	3.22
Catamarca	1.29	1.81	3.10
Neuquén	1.18	1.62	2.80
San Luis	0.68	2.04	2.72
Formosa	0.89	1.79	2.68
Mendoza	0.76	1.78	2.54
Tucumán	0.84	1.62	2.46
Bs. As.	1.31	1.12	2.43
Salta	1.46	0.83	2.29
Santiago del Estero	1.05	1.23	2.28
Córdoba	1.12	1.15	2.27

Provincia	Tasa cardiopatías	Tasa otras malf.	Tasa total
Jujuy	0.94	1.26	2.20
Santa Fe	0.95	1.19	2.14
Río Negro	0.74	1.19	1.93
Entre Ríos	0.64	1.28	1.91
Santa Cruz	0.37	1.48	1.85
Tierra del Fuego	1.59	0.00	1.59
CABA	0.61	0.98	1.58
Chubut	0.59	0.99	1.58
La Pampa	0.33	0.33	0.66




Figura 5. Tasa de cardiopatías congénitas vs. otras malformaciones por provincia (x1.000 nacidos vivos). A diferencia de un gráfico de valores absolutos, esta normalización permite comparar correctamente el peso relativo de cada tipo de malformación entre provincias de distinto tamaño poblacional.

Al normalizar por tasas, el panorama cambia respecto de los números absolutos: Chaco y La Rioja encabezan tanto la tasa total como -particularmente- la de otras malformaciones (2,16 y 2,85 por mil, respectivamente), mientras que Tierra del Fuego, pese a su bajo volumen absoluto, presenta una tasa de cardiopatías relativamente alta (1,59) y nula tasa de otras malformaciones. Esto confirma que trabajar con tasas, y no con conteos crudos, es la forma correcta de comparar el fenómeno entre unidades geográficas de tamaño desigual.

4.3.4 Distribución por región y tipo de malformación

Región	Cardiopatías	Otras malf.	Total
Pampeana	285	282	567
NEA	82	91	173
NOA	58	68	126
Cuyo	35	65	100
Patagónica	19	28	47

4.4 Estadísticas descriptivas de la tasa de mortalidad

Medida	Valor
Media	2,4462
Mediana	2,36
Moda	1,58
Varianza	0,5902
Desviación estándar	0,7683
Q1 (25%)	1,925
Q3 (75%)	2,875
IQR (Q3-Q1)	0,95
Percentil 10	1,583
Percentil 90	3,497
Provincia con mayor tasa	Chaco (3,90)
Provincia con menor tasa	La Pampa (0,66)

La diferencia entre media (2,45) y mediana (2,36) indica la presencia de provincias con tasas extremas que elevan el promedio. La desviación estándar (0,77) refleja una dispersión considerable entre provincias, evidenciando desigualdades territoriales. La brecha entre la provincia con mayor tasa (Chaco) y la de menor tasa (La Pampa) — casi 6 veces superior — evidencia inequidades estructurales en el acceso a la salud materno-infantil. Las provincias por encima del percentil 90 (Chaco, La Rioja, Corrientes) representan las jurisdicciones prioritarias para una eventual intervención del Ministerio de Salud.

4.5 Análisis etario

Subgrupo etario	Cardiopatías	Otras malf.	Total
Neonatal precoz (0-6 días)	114	257	371
Neonatal tardío (7-27 días)	115	90	205
Postneonatal (28 días-1 año)	250	187	437

La mayoría de las defunciones (437 de 1.013, 43%) se concentra en el período post-neonatal (28 días a 1 año), aunque el período neonatal precoz (0-6 días) también reúne una proporción muy relevante de casos (371, 37%), con fuerte predominio de otras malformaciones (257 de 371) sobre cardiopatías (114) en ese subgrupo. En el período neonatal tardío, en cambio, las cardiopatías superan levemente a las otras malformaciones.




Figura 6. Casos por subgrupo etario.




Figura 7. Distribución del tipo de malformación (TARGET) por subgrupo etario.

5. Pre-procesamiento y Reducción de Dimensionalidad

Se construyó un pipeline de pre-procesamiento con scikit-learn (ColumnTransformer + Pipeline) que combina imputación, escalado y codificación de variables, con el fin de dejar el dataset listo para el modelado:

- Variables numéricas (CANTIDAD, NACIDOS_VIVOS, TASA_MORTALIDAD): imputación por mediana (SimpleImputer) y estandarización (StandardScaler).
- Variables categóricas (PROVINCIA, REGION, PER_DEF, CAUSA): imputación por moda (most_frequent) y codificación One-Hot con manejo de categorías desconocidas.

Esta combinación produjo un dataset intermedio de 611 filas por 78 columnas. Para reducir la dimensionalidad conservando la mayor parte de la información, se aplicó un Análisis de Componentes Principales (PCA) configurado para retener el 95% de la varianza explicada, lo que permitió reducir el dataset de 78 a 33 componentes.




Figura 8. Varianza acumulada explicada en función del número de componentes principales (PCA).

Para el modelado predictivo final se optó, en cambio, por un enfoque más liviano y con menor riesgo de sobreajuste: TargetEncoder para las variables categóricas de alta cardinalidad (CAUSA y GRUPEDAD/PER_DEF), que redujo el dataset de 78 a solo 5 columnas manteniendo el mismo poder predictivo, sin necesidad de PCA.

6. Modelado Predictivo

Se entrenaron y compararon dos algoritmos de clasificación binaria para predecir la variable ENFERMEDAD (cardiopatías vs. otras malformaciones) a partir de variables numéricas (CANTIDAD, NACIDOS_VIVOS, TASA_MORTALIDAD) y categóricas de alta cardinalidad codificadas con TargetEncoder (CAUSA, GRUPEDAD). El conjunto de datos se dividió en entrenamiento (80%) y prueba (20%) mediante muestreo estratificado (train_test_split, random_state=42).

6.1 Regresión Logística

Se entrenó un modelo de Regresión Logística (class_weight='balanced', max_iter=1000) sobre el conjunto de entrenamiento. Sobre el conjunto de prueba (123 casos) se obtuvo el siguiente desempeño:

Clase	Precisión	Recall	F1-score	Soporte
Cardiopatías	1,00	1,00	1,00	44
Otras malformaciones	1,00	1,00	1,00	79
Accuracy			1,00	123

6.2 Optimización de hiperparámetros (GridSearchCV)

Se realizó una búsqueda exhaustiva de hiperparámetros mediante validación cruzada de 5 folds (GridSearchCV, scoring='f1_weighted') sobre el parámetro de regularización C, el solver y el número máximo de iteraciones, evaluando 16 combinaciones (80 ajustes en total). Los mejores hiperparámetros encontrados fueron:

Hiperparámetro	Valor óptimo
C	0,1
max_iter	500
solver	lbfgs
Mejor F1 (validación cruzada)	0,9980

6.3 Random Forest

Como segundo modelo se entrenó un Random Forest (100 árboles, class_weight='balanced') sobre el mismo esquema de variables. El desempeño sobre el conjunto de prueba fue idéntico al de la Regresión Logística:

Clase	Precisión	Recall	F1-score	Soporte
Cardiopatías	1,00	1,00	1,00	44
Otras malformaciones	1,00	1,00	1,00	79
Accuracy			1,00	123

AUC-ROC: 1,0000.




Figura 9. Importancia de variables del modelo Random Forest.

El análisis de importancia de variables muestra que la variable CAUSA (código CIE-10 específico) concentra la mayor parte del poder predictivo del modelo, muy por encima de las variables geográficas y demográficas.

7. Evaluación y Comparación de Modelos

Modelo	F1-score	AUC-ROC
Regresión Logística	1,0000	1,0000
Random Forest	1,0000	1,0000




Figura 10. Matrices de confusión — Regresión Logística vs. Random Forest.




Figura 11. Curvas ROC y de Precisión-Exhaustividad para ambos modelos.

Ambos modelos alcanzaron métricas perfectas de clasificación ($F1 = 1,00$, $AUC\text{-}ROC = 1,00$). Este resultado, si bien supera ampliamente el umbral de $F1 > 0,70$ planteado en la hipótesis, debe interpretarse con cautela: se explica por la relación determinista entre la variable CAUSA y la variable objetivo (ENFERMEDAD), dado que los propios códigos CIE-10 Q20-Q28 definen directamente qué casos son cardiopatías. En un escenario de aplicación real donde la variable CAUSA específica no estuviera disponible al momento de la predicción (por ejemplo, para anticipar el tipo de malformación antes de contar con el diagnóstico definitivo), las métricas esperables serían sensiblemente más moderadas.

8. Conclusiones

1. Análisis territorial. El análisis de la tasa de mortalidad infantil por malformaciones congénitas evidenció desigualdades significativas entre provincias y regiones. Las regiones NEA y Cuyo presentan tasas más elevadas respecto de las regiones Pampeana y Patagónica, lo que refleja brechas estructurales en el acceso a la salud materno-infantil.

2. Análisis etario. La mayoría de las defunciones por malformaciones congénitas se concentran en el período neonatal precoz y postneonatal, lo que sugiere que las cardiopatías congénitas son detectadas tardíamente o no cuentan con intervención quirúrgica a tiempo.

3. Modelo de clasificación. Ambos modelos (Regresión Logística y Random Forest) alcanzaron métricas perfectas ($F1 = 1,0$, $AUC\text{-}ROC = 1,0$). Este resultado se explica por la relación determinista entre la variable CAUSA y la variable objetivo — los códigos CIE-10 Q20-Q28 definen directamente las cardiopatías. En un escenario real donde CAUSA no estuviera disponible, las métricas serían más moderadas.

4. Reducción de dimensionalidad. El pipeline con PCA redujo el dataset de 78 a 33 componentes conservando el 95% de la varianza. El TargetEncoder redujo adicionalmente de 78 a 5 columnas manteniendo el mismo poder predictivo.

5. Recomendación. Se recomienda al Ministerio de Salud focalizar recursos en la detección prenatal de cardiopatías congénitas en las provincias del NEA y Cuyo, priorizando intervenciones en el período neonatal precoz.